

Aprendizado de Máquinas

Aula 06 – Regressão Logística



UNICAMP

Marcos Eduardo Valle
Matemática Aplicada
IMECC - Unicamp



Introdução

A regressão logística é uma técnica de aprendizado de máquinas usada em problemas de classificação binária.

Um classificador é uma função $\psi : \mathcal{X} \rightarrow C$, em que $\mathcal{X}$ é o espaço das características ou entradas e C é o conjunto das classes ou rótulos.

No contexto de aprendizado de máquinas supervisionado, o classificador $\psi : \mathcal{X} \rightarrow C$ é determinado usando um conjunto de treinamento

$$\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathcal{X} \times C. \quad (1)$$

Note que o conjunto de treinamento possui m pares $(\mathbf{x}_i, y_i)$ de amostras.

Na classificação binária, o conjunto das classes possui apenas dois elementos, ou seja, $\text{Card}(C) = 2$.

Note que o conjunto das classes $C = \{c_0, c_1\}$ pode ser identificado com o conjunto $\{0, 1\}$, bem como com o conjunto $\{-1, +1\}$.

A regressão logística é dada pela composição de um regressor linear com a função logística.

Formalmente, a regressão logística define uma função $f_{\theta} : \mathbb{R}^n \rightarrow [0, 1]$ dada por

$$f_{\theta}(x) = \sigma \circ h_{\theta}(\mathbf{x}) = \sigma(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n), \quad (2)$$

em que a função logística $\sigma : \mathbb{R} \rightarrow [0, 1]$ é dada por

$$\sigma(t) = \frac{1}{1 + e^{-t}}. \quad (3)$$

A regressão logística é usada em problemas de classificação binária porque podemos interpretar $f_{\theta}(\mathbf{x})$ como a probabilidade $\hat{p}$ de $\mathbf{x}$ pertencer à uma das duas classes.

Note que a probabilidade de $\mathbf{x}$ pertencer a outra classe é $1 - f_{\theta}(\mathbf{x})$.

Logo, podemos definir um classificador binário $\psi : \mathbb{R}^n \rightarrow \{0, 1\}$ como segue usando a regressão logística:

$$\psi(\mathbf{x}) = \begin{cases} 1, & f_{\theta}(\mathbf{x}) \geq 0.5, \\ 0, & \text{caso contrário.} \end{cases} \quad (4)$$

Equivalentemente, como $\sigma(t) \geq 0.5$ se, e somente se $t \geq 0$, temos

$$\psi(\mathbf{x}) = \begin{cases} 1, & h_{\theta}(\mathbf{x}) \geq 0, \\ 0, & \text{caso contrário.} \end{cases} \quad (5)$$

Treinamento da Regressão Logística

Dado um conjunto de treinamento

$$\mathcal{T} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} \subset \mathbb{R}^n \times \{0, 1\},$$

o vetor de parâmetros $\theta = (\theta_0, \theta_1, \dots, \theta_n) \in \mathbb{R}^{n+1}$ da regressão logística pode ser determinado minimizando a entropia binária cruzada (*binary cross-entropy*) dada por


$$\mathcal{L}(\theta) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)], \quad (6)$$

em que $\hat{p}_i = f_{\theta}(\mathbf{x}_i)$ representa a probabilidade estimada pelo modelo de $\mathbf{x}_i$ pertencer a classe 1.

Note que a entropia binária cruzada é a média dos termos

$$-[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] = \begin{cases} -\log(\hat{p}_i), & y_i = 1, \\ -\log(1 - \hat{p}_i), & y_i = 0. \end{cases} \quad (7)$$

A figura abaixo mostra o gráfico de $-\log(\hat{p}_i)$ e $-\log(1 - \hat{p}_i)$.




Note que $-\log(\hat{p}_i)$ é grande para valores próximos de zero enquanto $-\log(1 - \hat{p}_i)$ é grande para valores próximos de 1. Sobretudo, ambos os casos penalizam uma discrepância entre y_i e $\hat{p}_i$.

Diferente da regressão linear e da regressão ridge, não existe uma fórmula fechada para o vetor dos parâmetros que minimiza a entropia binária cruzada.

Todavia, a entropia binária cruzada é uma função convexa e, portanto, o mínimo da função perda $\mathcal{L}$ pode ser determinado usando métodos de otimização como o método de máxima descida ou o gradiente descendente estocástico.

Exemplo


A figura abaixo mostra o diagrama de dispersão de um conjunto de dados para a classificação binária.



Usando a regressão logística, encontramos o classificador descrito pela equação (5) com:

$$h_{\theta}(\mathbf{x}) = 0.57 + 1.15x_1 - 4.46x_2.$$

A figura abaixo mostra a superfície de decisão da regressão logística e o diagrama de dispersão de um conjunto de treinamento.



Note que as classes são separadas por uma reta.

De um modo geral, a regressão logística separa as duas classes pelo hiperplano

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n = 0. \quad (8)$$

Contudo, podemos obter um classificador não linear aplicando um pré-processamento não-linear em $\mathbf{x}$ antes da regressão linear.

Especificamente, podemos considerar a uma transformação ϕ que transforma $x_1, \dots, x_n$ em novas características $\phi_1, \dots, \phi_k$ e aplicar a regressão logística em $\phi_1, \dots, \phi_k$.

Nesse caso, temos o classificador dado por (5) com

$$h_{\theta}(\phi(\mathbf{x})) = \theta_0 + \theta_1 \phi_1 + \dots + \theta_k \phi_k. \quad (9)$$

Exemplo


Considere a transformação $\phi : \mathbb{R}^2 \rightarrow \mathbb{R}^9$ dada por

$$\phi(x_1, x_2) = (x_1, x_2, x_1^2, x_1 x_2, x_2^2, x_1^3, x_1^2 x_2, x_1 x_2^2, x_2^3).$$

Nesse caso, encontramos para o problema anterior o classificador dado por (5) com

$$\begin{aligned} h_{\theta} \circ \phi(\mathbf{x}) = & 58.42 - 50.27x_1 - 55.43x_2 \\ & - 112.11x_1^2 - 18.30x_1x_2 - 7.30x_2^2 \\ & + 82.49x_1^3 - 21.10x_1^2x_2 + 23.53x_1x_2^2 - 42.96x_2^3 \end{aligned}$$

A figura abaixo mostra a superfície de decisão da regressão logística com características polinomiais e o diagrama de dispersão de um conjunto de treinamento.



Note que as classes não são mais separadas por uma reta.

Métrica de Desempenho – Acurácia

Podemos utilizar a acurácia para avaliar o desempenho de um classificador binário.

A acurácia de um classificador binário $\psi : \mathcal{X} \rightarrow \{0, 1\}$ é dada pela equação

$$\text{Acurácia} = \frac{1}{m} \chi[y_k = \psi(\mathbf{x}_k)], \quad (10)$$

em que

$$\chi[s] = \begin{cases} 1, & s \text{ é verdadeira,} \\ 0 & \text{caso contrário,} \end{cases}$$

é a função indicadora da sentença (afirmação) s .

A acurácia dos modelos dos exemplos anteriores foram:

$$\text{Acurácia}(\text{linear}) = 0.876 \quad \text{e} \quad \text{Acurácia}(\text{não-linear}) = 1.0.$$

Considerações Finais

Na aula de hoje, apresentamos a regressão logística dada pela composição de uma função hipótese linear h_{θ} com a função logística, ou seja, $f_{\theta} = \sigma \circ h_{\theta}$.

A função logística pode ser usada para problemas de classificação binária, em que o classificador é dado por $\psi(\mathbf{x}) = \chi[f_{\theta}(\mathbf{x}) \geq 0.5]$.

Nesse caso, $f_{\theta}(\mathbf{x})$ é interpretada como uma probabilidade e o vetor de parâmetros é determinado minimizando a entropia binária cruzada (*bináry cross-entropy*).

Finalmente, a superfície de decisão da regressão logística é um hiperplano no espaço das características.

Muito grato pela atenção!